

A200S：高性能混合内核操作系统

从 MCU 到完整桌面：双重 ABI · 八大平台 · 工程化并发安全



AAAAAAAAAAAAAAAAAAAAA

武汉大学 | 2026 年 8 月

A200S

目录

01 项目概览

02 核心架构

03 并发与调度

04 内存管理

05 Linux ABI 兼容

06 Native ABI

07 混合内核服务与 IPC

08 文件系统与网络

09 图形与桌面

10 性能

11 驱动与平台

12 工程化与验证

13 未来工作

01

项目概览

19.2 万

自研代码行数

500

双 ABI syscall (361 +
139)

8

指令集架构

483

次提交 / 20 周连续演
进



A200S 是什么？——一页看完成度

- **混合内核**：性能路径留内核，易崩服务迁用户态
- **双重 ABI**：361 Linux syscall 兼容 + 139 Native syscall
- **八大平台**：7 hosted + ARMv7-M；星光 2 / LS2K1000 / STM32
- **完整桌面**：Wayland + LVGL 自研桌面 + virtio-gpu 3D
- **工程化**：锁契约文档化、54 项冒烟门禁、七架构矩阵

同一内核：从 64 KiB Flash 的 MCU，跑到 QEMU 桌面。

180/180

BuildStorm 用例全过（双架构）

54

项行为冒烟门禁（make smoke-*）

92 篇

设计文档，1.6 万行，随码同仓

从初赛到决赛：能力跃迁

维度	初赛	决赛（当前）
支持架构	4 个	7 hosted + ARMv7-M MCU
Linux ABI	部分 syscall	361 全表覆盖 ，含 io_uring / landlock / mseal
Native ABI	90 syscall	139 syscall + Pager / monitor 深化
调度器	8 级 MLFQ	EEVDF + per-CPU 队列 + 空闲窃取
桌面	-	Wayland 桌面 + virtio-gpu 3D
混合内核服务	-	svcmgr / 用户态驱动 / KEP 扩展
BuildStorm 耗时	2551 s / 2315 s (RV / LA)	1483 s / 1399 s (-42% / -40%)

从“能启动、能跑几个程序”进化到**可跑完整桌面、可跑决赛高性能负载**的通用内核。

从零开始：不基于任何现有内核

- **首个 commit** (2026-04-11): 8,052 行最小内核 + 基础用户程序; 此后 **483 次提交、20 周连续演进**
- **无一次性导入**: 最大单 commit 即首个最小内核, 其余全部是 $\leq 7.5k$ 行的增量功能提交
- **内核树零 submodule**: 23 个 submodule 全部是用户态应用 / 库 / 工具链 (vim、git、LVGL 等), 隔离于 user/external/
- 内核唯一第三方组件: **lwIP 协议栈**, 目录级隔离于 kernel/external/, 不计入自研工作量
- 非衍生自 Linux / xv6 / rCore / FreeRTOS / RT-Thread / ArceOS 等任何现有内核


证据即仓库: `git log --reverse` 逐 commit 可查; 第三方边界有编译期门禁审查



■ 自研内核 15.7 万 ■ 自研用户态 3.5 万 ■ lwIP (隔离) 6.5 万

内核主干 **100% 自研**; 另含 **18 个** 编译器注册驱动、**53 个** 自研用户态命令 / 测试程序。


20 周、483 次提交：从 8k 行最小内核到 16 万行内核



里程碑（首个实现日期）

- 04-11 最小内核（8k 行）
- 04-12 ext4 + 块缓存
- 04-27 网络栈（lwIP 接入）
- 05-14 Native ABI 起步
- 06-02 SMP 多核基础设施
- 06-09 x86_64 端口
- 07-13 GPU 驱动 / STM32 MCU
- 07-27 Wayland 桌面 + 音频
- 08-02 EEVDF + Channel IPC
- 08-06 IOMMU + 用户态驱动
- 08-10 Linux syscall 全表覆盖
- 08-14 Native 深化（Pager 等）

代码分布：19.2 万行自研代码花在哪里



内核自研 15.7 万行（千行 / 模块）；第三方（lwIP / musl）隔离于 external/，不计入。

工作量最高的三块

文件系统 29.5k: VFS + ext4(JBD2) + FAT32 + NTFS 等 6 类后端

驱动 26.1k: virtio 全家桶 + USB/x-HCI + HDA + PCI/ECAM

架构 23.8k: 7 架构 HAL + SMP + 异常/信号上下文

- 统一 Makefile 七架构构建矩阵
- 文档化锁契约与并发门禁
- 可选 ccache 透明加速

跨平台能力矩阵：一套代码，八种指令集

架构	SMP	NOMMU	GUI	真机 / VM
RISC-V 64 *	✓	✓	✓	✓ 星光 2
LoongArch 64 *	✓	-	✓	✓ LS2K1000
aarch64	✓	✓	✓	✓ VirtualBox
x86_64	✓	-	✓	✓ VirtualBox
arm32	-	✓	✓	-
riscv32	-	✓	-	-
ppc64le	-	-	-	-
armv7m (MCU)	-	✓ (仅)	-	✓ STM32

8 个 ISA全部可构建启动；**4 架构** SMP 已验证；**5 架构**可关 MMU 构建 (smoke-arch-mm-matrix 把关)；**5 架构** GUI 行为冒烟。

* = 决赛双架构；make all 产出 kernel-rv/la 与 disk(-la).img；VirtualBox 经 UEFI + ACPI 引导。

02

核心架构

一个内核、两套接口：Linux ABI 负责兼容生态，Native ABI 探索下一代安全内核 API；混合内核按“高频路径留内核、易崩服务迁用户态”判定分层。


双重 ABI：一个内核、两套接口

Linux ABI 兼容层 kernel/abi/linux/

- **361 个 syscall** 调度表全表覆盖，无空位占位
- 现代机制：io_uring、landlock、pidfd、userfaultfd、mseal、perf_event_open
- 直接运行 musl 生态与完整 Linux 用户态


Native ABI 能力层 kernel/abi/native/

- **139 个原生 syscall**，Capability 对象句柄
- VMO / VMAR、Channel、EventQ、Pager
- 无 fork/exec/signal/ioctl 的干净底座



设计价值：既有 Linux 用户态生态（musl、gcc、vim、rustc、FFmpeg），又为下一代安全内核 API 提供演进底座。


混合内核架构形态



判定规则：**高频 / 延迟敏感路径留在内核**；**崩溃频繁、协议解析类工作迁到用户态服务。**

分层原则：内部实现 ⊗ ABI 薄包装

- 调度、MM/VMA、VFS、页缓存等状态归属**内部核心层**，与 ABI 无关
- ABI 层只做**线格式翻译**，内部 API 单向依赖
- 内部 IPC 头位于 `kernel/include/ipc/`，不包含任何 `abi/` 内容
- Linux 线格式常量由 `kernel/include/core/*.h` 自持



收益：任意新 ABI (含 Linux) 直接包装内部机制即可受益，无需复制实现；门禁 `check-abi-boundary` 编译期审查依赖方向。

锁契约：SMP 并发的基础

```
1  /* 全局锁序契约（节选） */
2  cg_node.lock -> proc_lock -> runq.lock
3                      -> pfa.lock
4  proc_lock -> signal_state.lock
5  proc_lock -> files_struct.lock
6                      -> VFS locks
7  proc_lock -> mm_struct.lock
8  proc_lock -> a20_handle_table.lock
9  g_lwip_lock -> g_net_lock
```

全文：docs/drivers/lock-order.md；新锁必须先文档化再合入。

- 摒弃全局大锁，确立严格**局部锁层级**
- 本地调度 picker 只持本 CPU runqueue 锁（唯一例外）
- ext4 命名空间锁改**读写锁**：8 个并发 rustc 的 dcache 查找互不排队
- 8 核压力门禁常驻：make smoke-sched-stress 等

核心规则：持 runq_lock 时永不取 proc_lock；持 spinlock 时永不阻塞；持设备 / lwIP 锁时不调用 VFS/mm/调度器（除非文档化为非阻塞）。

03

并发与调度

per-CPU EEVDF 调度器：nice 权重比 489:1、基准时间片 10 ms 运行时可调；tokenized park/wake 消除丢失唤醒；8 核压力门禁常驻回归。



EEVDF 调度器：公平与延迟的统一

- **按权记账**：nice 真实控制 CPU 份额（权重表与 Linux 同源）
- **系统虚拟时间**资格门控 + 虚拟截止时间
- RT（级 0，SCHED_FIFO/RR）恒优先于 EEVDF
- **空闲窃取**：本地队列空时拉取远端富余任务
- sleeper bonus 由 EEVDF_MAX_LAG 钳制（10 ms）
- /proc/a20/sched_base_slice 运行时切换桌面 / HPC 形态

关键文件：kernel/proc/sched.c；设计文档：
docs/eevdf-scheduler.md

EEVDF 核心公式

$$\text{vruntime} += dt \times \frac{\text{NICE0}}{\text{weight}}$$

$$\text{vtime} += dt \times \frac{\text{NICE0}}{\sum \text{weight}}$$

$$\text{eligible: } \text{vruntime} \leq \text{vtime}$$

$$\text{deadline} = \text{vruntime} + \frac{\text{slice} \times \text{NICE0}}{\text{weight}}$$

nice -20 / +19 权重 43020 / 88，份额比约 **489:1**；
基准 slice 10 ms。

Tokenized Park/Wake 与任务所有权

- 三个**相互独立**的状态维度：语义状态 / 调度所有权 / Park
- (task, wait_seq) token 消除**丢失唤醒窗口**
- on_rq → dispatching → on_cpu 显式所有权交接
- timeout 最小堆：O(log n) 取消，**唯一摘除**
- 唤醒原因显式区分 event / timeout / signal / exit / cancel

关键文件：kernel/proc/park.c、
kernel/proc/sched.c、
kernel/include/core/sync.h



wait_seq 每次 prepare 递增；延迟事件必须同时匹配 task 与 wait_seq，否则视为旧 token 丢弃。

SMP 负载均衡与持久抢占

- **Per-CPU 运行队列**：消除全局调度锁
- 空闲窃取只发生在本地队列空时，**只窃 EEVDF 任务、远端 $nr_running \geq 2$ 、尊重 affinity**
- 跨队列迁移按**CPU 编号升序**锁定，runqueue 引用全程有效
- **持久 need_resched**：远程唤醒先发布状态，再置标志
- IPI 只负责**通知**，不在任意中断上下文直接切换；请求在 syscall / trap / timer 返回等安全点消费
- 远程唤醒统一走 priority-preempt 快路径，**两个 ABI 共享** (pipe / AF_UNIX / futex / channel)

关键文件：kernel/proc/sched.c、kernel/include/proc/proc.h；8 核压力门禁 make smoke-sched-stress，双架构 1 核 / 8 核累计矩阵 make check-proc-step8-local

04

内存管理

VMO/VMAR 解耦物理页与地址空间；大页降级、COW、MAP_SHARED 脏页生命周期完整；Pager 把缺页变成用户态可处理的 channel 消息。

VMO/VMAR：解耦物理页与地址空间

- **VMO** (Virtual Memory Object)：物理页容器，可 resize、共享、按页 fault
- **VMAR** (Virtual Memory Address Region)：地址空间布局，负责映射与权限
- 保护公式： $\text{effective_prot} = \text{vmo_prot} \cap \text{vmar_prot} \cap \text{map_prot}$
- 共享映射：多个 VMAR 映射同一 VMO，实现**零拷贝共享内存**

```
1 // VMO resize / commit / decommit
2 a20_vmo_set_size(h, new_size);
3 a20_vmo_op_range(h, COMMIT, off, len);
4 a20_vmo_op_range(h, DECOMMIT, off, len);
```

```
1 // 零拷贝共享内存 IPC
2 a20_vmo_create(PAGE_SIZE, 0, &vmo);
3 a20_vmar_map(sender, vmo, ...);
4 a20_channel_write(ch, ..., &vmo, 1);
5 a20_vmar_map(receiver, vmo, ...);
```

关键文件：kernel/mm/a20_vmo.c、kernel/abi/native/vmar.c；压力门禁 `make smoke-mm-stress`

大页降级、COW 与 MAP_SHARED 一致性

- `mm_demote_huge_page()`: 将 2 MiB 大页安全拆分为 4 KiB 页
- `mm_fork_clone_present_level()`: fork 时建立**写时复制**映射
- `mm_sync_shared_dirty_for_vnode()`: 维护 MAP_SHARED 脏页生命周期
- **per-mm TLB invalidation transaction**: 旧 frame 延迟到远端 shutdown 完成后才释放 (并行 rustc 崩溃的根因修复)
- `mm->lock` 锁模型保证多核 `mmap/munmap/fault` 并发安全; `mseal` 封禁 VMA

关键文件: `kernel/mm/vm.c`、`kernel/fs/page_cache.c`、`kernel/include/mm/vm.h`

压力门禁: `make smoke-mm-stress`
(write/read、fsync、truncate、fork、remap、eviction)

Pager: 用户态驱动的按需分页

- **PAGED VMO** 缺页不静默填零，而是把页请求作为 channel 消息交给 **pager 线程**
- pager 用 `pager_supply_pages` 回填后唤醒 faulting 线程
- 对齐 Zircon `zx_pager_*`，去掉 `fd / ioctl` 面
- 页供给不跨越 BLP 标签（源 `label ≤ VMO label`）

关键文件：`kernel/mm/vmo.c`（PAGED 分支）、`kernel/abi/native/sys_native_ipc.c`；验证 `make smoke-native-deepen`

页请求消息

类型 `READ/WRITE`（缺页访问类型），`data0` = 缺失页在 VMO 内字节偏移；pager 回填后唤醒该页的 `waiters`。

适用场景

持久化内存、用户态 `swap pager`、虚拟化内存后端、快照 / 迁移。

05

Linux ABI 兼容

361 个 syscall 调度表全表覆盖、无空位；io_uring / landlock / pidfd / mseal 等现代机制已实现；动态链接 musl 程序直接运行。

全量 syscall 覆盖：361 项，无一空位

- **361 个 syscall** 调度入口，四条主线架构编号**全表覆盖**
- x86_64 表扩展至 **463 槽**；LoongArch 私有 file_getattr/setattr
- 每个注册项都有真实 handler——**没有任何固定返回 -ENOSYS 的占位槽**
- 逐项语义等级（full / partial）记录在案，不虚报完成度

覆盖口径：

kernel/abi/linux/syscall_coverage.md；验证
make smoke-abi-linux、make smoke-syscall-ext

已实现的高复杂度机制

- openat2 (RESOLVE_CACHED)、renameat2、statx
- futex PI + robust、membarrier
- splice/tee/vmsplice、eventfd/timerfd/signalfd
- ptrace SEIZE/INTERRUPT、fanotify、keyring、AIO
- mseal VMA 封禁、sched_attr 完整解析

动态链接与用户态生态

- `exec` 正确处理 shebang 与 ELF interpreter (`/lib/ld-musl-*.so.1`)
- `MAP_PRIVATE` / `MAP_FIXED`、TLS (tp 寄存器) 正确建立
- 全部 musl 动态链接的二进制可直接运行
- 用户指针边界显式处理 (identity-mapped 架构下不误判 `argv/envp` 来源)

关键文件: `kernel/proc/exec.c`、
`kernel/fs/vfs/path_resolution.c`

可运行的用户态生态

musl • git • vim • gcc • fastfetch • mksh
• coreutils • rustc (Cargo) • FFmpeg

这是完整桌面能起来的地基；早期 musl 加载期空指针崩溃即从 `exec/mmap` 语义修正而来。

vDSO：零陷入时钟快路径（实测 -44% 延迟）

- `clock_gettime / gettimeofday / getcpu` 用户态零陷入
- riscv64 与 **loongarch64** 双架构实现，经 `AT_SYSINFO_EHDR` 导出
- `vvar` 数据页与内核 `timekeeping` 位级一致，`seqlock` 保护
- `musl` 的 `VDSO_USEFUL` 自动接管，程序零改动获益

关键文件：`kernel/vdso/`；验证 `make smoke-clock-vdso`



LA64 QEMU TCG 实测：-43.7%。

06


Native ABI

139 个能力化 syscall 表达 361 个 Linux syscall 的功能面（约 2.6 倍压缩）；14 位权利掩码 + BLP 标签 + 时间能力构成句柄安全模型。

Native ABI 设计哲学：2.6 倍接口压缩

- **系统调用压缩**：361 Linux → **139 Native** (约 2.6×)
- **统一抽象**：handle_set_meta 替代 chmod/chown/utimes/truncate；handle_transfer 统一 splice/sendfile/tee 等
- **版本化 ABI**：复杂结构以 size + version 开头，运行时协商
- 无 fork/exec/signal/ioctl；以 task_spawn、Channel、EventQ 替代
- 编号稳定分区 (0x0000-0x0FFF)，遵循 E-APPEND / E-DEPRECATE 演进规则

关键文件：kernel/abi/native/syscall_table.def
(139 项 X-macro 注册)



对照教学内核 xv6-riscv (全表 23 个)：
A20OS Linux 兼容面约为其 **15.7 倍**；Native
以 139 入口表达同一功能面。

Native ABI 深化：把 Linux 机制对象化

- **Pager (0x0D00)**: userfaultfd 的对象化——PAGED VMO + channel 页供给
- **monitor (0x0D10)**: perf 软件事件的对象化——计数对象可订阅 EventQ
- **task_mem_read/write (0x0211/12)**: process_vm 的能力化随机访问
- **vm_share_region (0x030A)**: 按区间导出 VMO 句柄
- **EventQ FS/网络事件源**: vnode-keyed FS 事件 + socket/pipe 就绪边沿

设计文档：

`docs/native-abi/09-native-abi-deepening.md`;

验证 `make smoke-native-deepen`

三分设计原则

- **应包装**：以更干净的对象接口表达
- **应拒绝**：SysV IPC、io_uring、Landlock 保持 Linux-only，用 capability 替代
- **已有等价物**：pidfd → TASK handle、memfd → MEMORY handle

Handle 生命周期与安全模型

- **14 位权利掩码**: READ / WRITE / EXEC / STAT / DUP / TRANSFER / MAP / WAIT / CONNECT / ACCEPT / CONTROL / ADMIN / SIGNAL
- **权利单调递减**: handle_dup 与 IPC 转移只能缩小权利
- **Bell-LaPadula** 多级安全标签 {L, M, H}: no-read-up / no-write-down
- **Temporal capability**: 到期时间 + 操作次数限制, 自动失效

关键文件: kernel/abi/native/handle_table.c; 设计 docs/native-abi/06-security.md; 验证 make smoke-native-contract

Handle 不变式

同一 Handle 在一个进程表中只存在一份有效引用; IPC 共享传递是原子的, 不存在“悬挂引用”。接收方空间不足时整体返回 NO_SPACE, 杜绝 partial delivery。

07

混合内核服务与 IPC

Channel/EventQ 异步 IPC：单条消息 64 KiB + 8 Handle，要么完整交付要么不交付；svcmgr 崩溃自动重启 + 资源硬隔离；virtio-blk / RTC / input 已整体用户态化。



Channel / EventQ: 异步 IPC 协议

- **两阶段写入**: reserve → 拷贝 → commit; 失败可 abort
- 单条消息最多 **64 KiB 数据 + 8 个 Handle**
- Handle 共享语义: 发送方保留原 handle, 对象引用计数递增
- channel_call (0x0508) **一次陷入完成请求 + 回复**; UP 下时间片捐赠直接切换
- **统一等待对象层**: futex / EventQ / channel / pipe / socket 共用 wait_queue_t

关键文件: kernel/ipc/a20_channel.c、
a20_event.c; 验证 make smoke-native-ipc

SPSC 共享内存环

全相对偏移布局(跨进程可用); Dekker futex 门铃; **非满非空路径零 syscall**; 16 MiB 跨进程完整性验证。

交付保证

消息要么完整交付 (数据 + 所有 Handle), 要么完全不交付。

服务监管者、注册表与健康探针

- **服务监管者** (svcmgr): 声明式清单 + 依赖 + **崩溃自动重启** (指数退避 + flap 预算)
- **服务注册表**: 按名解析 + 崩溃后自动重绑 (CAS claim)
- **健康探针**: ping + 超时强杀, pong 通道随重启重注册
- **资源硬隔离**: 句柄配额 4096 + 对象计数审计 (/proc/a20/objects), 崩溃循环零漂移

验证: smoke-native-svc、smoke-native-registry、smoke-native-isolation、smoke-a20-channel

Linux ABI 透明获益

Linux 程序经
SYS_a20_channel_pair(900) /
SYS_a20_registry_client(901) 以
fd 表面消费同一 channel 机制与服务注册
表——Native 机制, Linux 程序零改动可用。

用户态驱动：能力化设备访问

- **MMIO 白名单授权 + IRQ → EventQ:**
goldfish RTC 整体用户态化 (rtcd)
- **virtio-blk 用户态驱动:** 零拷贝 DMA, FAT32 挂载 (ubd); 页缓存留内核, 块请求经共享环转发
- **驱动崩溃恢复:** 在飞请求失败传导 + 自动重挂载 (ubd_recover)
- **动态设备所有权:** device_claim/release, 任务退出自动释放
- **DMA 缓冲只能来自内核 VMO**
(device_alloc_dma 预物化连续堆)

验证: smoke-native-rtcd、smoke-native-ubd、
smoke-native-shmring、smoke-iommu-discovery

IOMMU 硬件隔离

riscv-iommu-pci bring-up: DDT/CQ/FQ 编程使能, devid 0 SV39 静态翻译域, TR_REQ 验证已映射 / 未映射 IOVA。

设备身份

*.a20drv 描述段声明 placement / 设备类型 / 稳定名 / 匹配表; 一个设备一个 owner。

KEP：内核扩展点（安全版 eBPF）

- 与 Linux LKM 本质不同：**受限字节码程序**，非任意原生代码
- 标准 eBPF 指令编码（struct bpf_insn），**同一份字节码**经 Native（ext_prog_load）或 Linux（bpf(2)）加载
- 无指针、无任意内存访问、无循环（严格向前跳转，**结构性终止**）
- 线性扫描**验证器**逐条检查，非法即拒绝
- 扩展点 = 类型化上下文；进程退出自动清理

关键文件：kernel/drvmod/
kernel/abi/native/sys_native_ext.c、
docs/extensions.md

第一个扩展点：syscall-filter

上下文 8 字：nr, arg0..5, abi。附着于每次系统调用入口，R0 判定放行 / 拒绝 / 终止。

验证

```
make smoke-native-ext、make bpf_smoke
```

08

文件系统与网络

高兼容 VFS: openat2 / renameat2 语义完整, ext4 带 JBD2 日志恢复; lwIP 事件驱动集成, 无编译期网络默认值。



高兼容 VFS 与路径解析

- `openat2` 语义: `RESOLVE_NO_XDEV`、`BENEATH`、`NO_SYMLINKS`、`RESOLVE_CACHED`
- `renameat2`: `RENAME_EXCHANGE`、`RENAME_NOREPLACE`、跨 mount 拒绝
- 正确处理 mount root、.. 穿越、符号链接深度限制 (`MAX_SYMLINKS=40`)
- Page Cache 与 block cache 统一, 保证多核一致性; 并发写回按 dirty generation 定序
- dcache 目录项缓存 + 模块化 `vfs/*.c` 单元

关键文件: `kernel/fs/vfs/path_resolution.c`、
`dcache.c`、`mount_ops.c`、`stat_perm.c`

关键不变式: `lookup` 必须持有父目录引用; `rename` 原子更新目录项与 inode `nlink`; 跨后端返回 `-EXDEV`。

文件系统后端契约矩阵

后端	rename	link	symlink	关键能力 / 限制
FAT32	×	×	×	元数据仅存 RAM
ext4	✓	✓	快链 ≤ 60B	JBD2 journal 恢复, 64 位文件索引无 B-tree 分裂
NTFS	✓	×	×	
ISO9660	×	×	×	
ramfs	✓	✓	✓	只读 CD-ROM
pipe	-	-	-	max inodes 4096
				PIPE_BUF 原子写

伪文件系统: devfs (动态 class 设备)、procfs (快照文件)、sysfs (/sys/class/{char,block,net,input,display,audio})、cgroupfs。
契约文档: docs/fs/fs-consistency-model.md、docs/fs/vfs-edge-semantics.md

事件驱动网络栈 + 运行时配置

- lwIP 以 NO_SYS=1 集成，避免多线程轮询
- kernel/core/progress.c 统一 **bottom-half** 进展机制
- virtio-net RX/TX 由**中断 + 事件**驱动
- 调度器切任务前运行 bottom-half，降低上下文切换开销

kernel/net/lwip_stack.c、
kernel/core/progress.c、
kernel/drivers/net/virtio_net.c

- **无编译期网络默认值**，缺失配置返回 -ENETUNREACH
- 内核命令行 a20.ip/gateway/dns/dhcp + /proc/net/config 运行时展示
- 套件：TCP/UDP/ICMP、DNS、AF_UNIX、AF_ALG、SCM_CREDENTIALS、netlink uevent

调用路径：网卡中断 → a20_lwip_poll() → progress_run() → socket bottom-half → 唤醒等待任务

09

图形与桌面


内核原生 DRM/KMS + evdev 支撑 Weston / labwc Wayland 桌面与 LVGL 自研桌面；virtio-gpu virgl 打通 3D 命令透传链路。



Wayland 桌面：内核原生支持（QEMU 实拍）

- 从源码**移植** wlroots / labwc / weston / xfce 4.20 组件，submodule 保持纯净
- **内核补齐**而非改组件绕行：少量用户态补丁构建期临时应用并还原
- 原生 libinput 后端经 libseat 打开 /dev/input/event*
- 帧调度链完整：commit → render → pageflip → vblank
- **LVGL 自研桌面**：仪表盘 / 终端 / 文件 / 进程监控

关键文件：kernel/drivers/gpu/drm.c；验证 make smoke-qemu-gui-riscv64（QMP 注入键鼠 + 截图判帧）



实拍：riscv64 QEMU，Weston 桌面内播放视频。

内核 DRM 强化与 3D 图形加速

内核 DRM 强化

- **唯一 KMS 对象 ID**: plane / crtc / connector / encoder 互不冲突
- 页翻转事件: FIFO 不覆盖、seq 单调、时间戳单调钟、EBUSY 语义
- 标准 32 字节 UAPI 结构, 杜绝栈溢出
- EDID blob property (含合成合规 EDID)

3D 链路: 用户态 → ioctl(/dev/dri/card0) → drm_ioctl → gpu_ioctl → SUBMIT_3D → virglrenderer → 宿主 GPU; 自测工具 gpu3d_test

3D: virtio-gpu virgl

- **内核 3D 命令路径完整**: feature 协商、capset、context / resource / submit 透传
- 渲染在宿主机, guest 内核只搬运命令与资源
- A20_GPU_IOCTL_* 经 /dev/dri/card0 暴露
- 与 2D fbdev 路径互不干扰, 无 virgl 自动回退

10

性能

面向 BuildStorm 热区的 14 项优化全部保留真实计时；双架构 BuildStorm 2551/2315 s → 1483/1399 s，用例 180/180 全过。



性能优化体系（面向 BuildStorm 热区）


- **用户 vDSO**: riscv64 / loongarch64 clock_gettime 零陷阱
- **COW 页错误 TLB 定向失效**: 广播 SBI/IPI → 只向 mm->active_cpus 定向
- **批量延迟 frame 释放**: frame_put_many 每 64 帧只取一次 pfa.lock
- **ext4 命名空间读写锁**: 8 个 rustc 的 dcache 查找不再互斥
- **VMA 索引 256 → 1024**: 编译器进程保持 $O(\log n)$ 二分
- **PRIVATE futex 跳过页表遍历**; fault 去冗余检查
- per-vnode 共享映射开关 + 热路径索引化, 消除全局脏页扫描

方法论

每项保留真实计时; 数字只按干净提交固定, 不外推。

文档: docs/BuildStorm-2026.md;
mm/futex/sched 等全组压力验证

决赛 BuildStorm: 双架构 180/180, 耗时下降约 40%



快照 d5ae5a16 / f3e3ce48 / f9732348, 同一 workload、8 vCPU、TCG multi; 与 Linux 基线跨 QEMU 版本。

-41.9% / -39.6%

RV / LA 相对优化前耗时下降

180/180

BuildStorm 用例通过 (双架构)

199.10/200

CAgent 得分 (10/10 通过)

决赛快照 f9732348: exit 0 主动关机, 产物 SHA-256 存档。

11

驱动与平台

混合驱动模型：零开销 MMIO + 统一 hwapi + 双部署 profile；drvmod 可加载模块约 80 个导出符号
唯一 API 面；下至 64 KiB SRAM 的 MCU。

混合驱动模型

- **零开销 MMIO**: 板级地址用宏内联, readl/writel 编译为单条 load/store
- **统一 hwapi**: request_irq、dma_alloc、clock_get_cycles 跨架构抽象
- **类 ops vtable**: block_dev_ops_t、net_dev_ops_t、char_dev_ops_t
- 编译期注册: DRIVER_REGISTER / BOARD_REGISTER 放入 .driver_init linker section
- 双部署 profile: generic (DriverStore + .a20drv) / embedded (静态链接, 决赛默认)
- drvmod: ET_REL 装载 + .a20drv 描述段 + veneer/GOT, **约 80 个导出符号**唯一 API 面

关键文件: docs/drivers/README.md、kernel/include/drivers/hwapi.h; 验证 make smoke-drvmod

设备生态：音频 / USB / PCI / 虚拟机

音频子系统

virtio-snd • Intel HDA (PCI class 驱动, CODEC 拓扑发现) • PC Speaker; /dev/audioN + capability/format 校验; audioplay 与 FFmpeg 播放器

USB 协议栈

host / class / core 分层; xHCI; HID / 存储类; make smoke-usb-x86_64

PCI 与平台设备

ECAM 枚举 • **e1000 真 PCI 网卡** • ahci • virtio-scsi • 平台网卡 (starfive_gmac / ls2k_gmac) • dw_sdio

VirtualBox

x86_64 / aarch64 经 **UEFI + ACPI + ECAM** 引导; VMSVGA / E1000 / VirtIO-SCSI

嵌入式与 MCU：同一内核，64 KiB SRAM 起步


STM32F103 (ARMv7-M / NOMMU)

- 64 KiB Flash / 20 KiB SRAM bring-up (QEMU 验证)
- 普中玄武 ZET6: 512 KiB Flash / 64 KiB SRAM
- 外设: LCD、舵机 / 执行器、DHT11 传感器、蓝牙、ESP8266、背光

PPC64LE 与跨平台工程

QEMU pSeries 固件 (MMU 单核边界); 统一 arch/HAL 抽象 + 七架构构建矩阵, 物理板与虚拟平台同构验证。

入口: `make stm32f103-xuanwu`、`make run-stm32f103-qemu`、`make ARCH=ppc64le run`




实拍：普中玄武 STM32F103ZET6 运行 A20OS，LCD 仪表盘 + 舵机 / DHT11 / 蓝牙外设。

12

工程化与验证

54 项行为冒烟门禁 + 15 项静态/运行时审查门禁；文档即事实契约保证设计与实现不漂移；/proc/a20 暴露运行时对象与调度计数。

测试门禁体系：54 项冒烟全部可复现



54 项 make smoke-* 按类别分布；明细见备查 D。

54

make smoke-* 行为冒烟门禁

61

项 check-* 审查 / 构建门禁

30+

自研压力 / 语义测试工具 (user/cmds)

调度压力矩阵 check-proc-step8-local:
双架构 1 核 / 8 核累计。

- DOCS_AS_FACT_CONTRACT：架构文档描述**当前实现**，未来设计放规划材料
- 20+ 静态审查门禁：锁模型、ABI 边界、I/O 进展模型、文档漂移等
- 外部依赖边界审查（musl / lwIP / 用户态工具）
- Docker 交叉编译环境 + 可选 ccache
- 92 篇设计文档、1.6 万行，随代码同仓演进

崩溃 / 重启循环后对象计数回归基线，泄漏审计可重复验证。

/proc/a20/ 运行时状态面

- objects：7 项实时对象计数 + 句柄硬配额审计
- task_lifetime：task/ref、runqueue、wait/wake、timeout、migration、IPI、violation 计数
- sched_base_slice：EEVDF 虚拟 slice 旋钮

13

未来工作



下一步工作

1. **I/O 完全事件驱动**：收敛块 / 网络设备最后的轮询 fallback 路径
2. **网络栈深化**：降低 g_lwip_lock 竞争，扩展 socket 并发测试
3. **VFS / Linux ABI 语义收紧**：partial → full 逐组提升
4. **IOMMU 动态 DMA**：per-device domain 与 fault 队列消费，端到端硬件隔离
5. **Native 多架构矩阵**：将 16 项原生测试扩展至全架构 CI-like 运行

核心追求：在保证 Linux 生态兼容的前提下，构建更安全、更高性能、更可维护的下一代内核底座。



Q & A

感谢各位专家评委，恳请批评指正

感谢全国大学生计算机系统能力大赛平台 · 感谢开源社区 AOSC、plos-clan 的支持

gitlab.eduxiji.net/T202610486999803/oskernel2025-a20 | github.com/fQwQf/A200S

备查 A: EEVDF 正确性与参数

- 权重表 `sched_prio_to_weight[40]` 与 Linux 同源：
`nice -20 → 43020`, `nice +19 → 88`
- `EEVDF_NICE0_LOAD = 1024`, 基准 slice 10 ms,
`EEVDF_MAX_LAG` 10 ms
- `eligibility`: $vruntime \leq vtime$; `pick`: `eligible` 中最小 deadline
- 延迟唤醒补偿按 lag 计入 `vruntime`, 但钳制到 `MAX_LAG`, 防止“睡一次吃光 CPU”

可能被问：与 Linux EEVDF 的差异

数据结构为 per-CPU 队列 + 显式所有权状态机，非 rbtrees 全局队列；RT 单独级 0 恒优先；slice 经 `/proc/a20/sched_base_slice` 运行时可调，用于桌面 / HPC 形态切换。

证据：`kernel/proc/sched.c`、`kernel/proc/proc_internal.h`、`docs/eevdf-scheduler.md`

备查 B：并行编译崩溃的根因与修复

- **现象**：8 核 / 8 job 全量 cargo 编译下，RISC-V64 rustc ICE；LoongArch64 SIGILL / SIGSEGV / 地址异常
- **根因**：清除或替换 PTE 后，旧 frame / page-cache 引用可能在**远端 TLB shutdown 完成前**被释放并复用——新写入落到旧物理页
- **修复**：per-mm TLB invalidation transaction，旧 backing 延迟到 shutdown 确认后释放；LoongArch64 同步等待远端 shutdown；统一 VMA deferred flush、slab、block-cache、buddy 的并发边界
- **另两处持久化损坏**：VirtIO packed used ring 16 位 idx 撕裂读（固定布局 + barrier）；block-cache 并发写回旧 ext4 bitmap 晚于新快照落盘（writeback/fill 锁 + dirty generation 定序）

完整分析与证据边界：docs/BuildStorm-2026.md §2；验证：并发 rustc + 官方测试组 + 定点 probe 交叉验证

备查 C: 361 / 139 的统计口径

- Linux ABI: `syscall_table.def` 注册 **361 个调度项** (含 2 个 A20 扩展、5 个 x86_64 legacy 槽), 每个注册项都有真实 handler
- 少数 `-ENOSYS` 返回是 Linux 本身的架构 / 版本正确语义 (如 `nfsservctl` 已于 Linux 4.19 移除)
- 语义等级逐区标注 full / partial, 见 `syscall_coverage.md`, 不夸大兼容度
- Native ABI: `syscall_table.def` 中 139 条 X-macro 注册

验证方法

`make smoke-abi-linux` 逐组语义验证; `smoke-syscall-ext` 覆盖 `io_uring` / `landlock` / `userfaultfd` / `perf` 等现代机制; 真实负载: musl 生态 + Cargo 全量编译。

备查 D: 54 项冒烟门禁明细

数量	类别	目标
16	Native ABI 专项	smoke-native-{contract,deepen,ext,futex,ipc, isolation,linux,mm,registry,rtcd,shmring,svc,ubd,...}
12	并发与压力	{mm,sched,futex,vfs,proc,procfs,pty,scm,signalfd,evdev}-stress 等
9	架构启动 / 矩阵	smoke-<arch> × 7 + smp-bringup + arch-mm-matrix
7	Linux ABI 语义	abi-linux、syscall-ext、ptrace、proc-a20、vfs-edge 等
5	GUI 行为判帧	smoke-qemu-gui-{riscv64,loongarch64,aarch64,x86_64,arm32}
2	IOMMU / 驱动隔离	iommu-discovery、iommu-udriver-isolation
2	时钟 / 输入	clock-vdso、dual-input
1	网络套件	smoke-network-suite (TCP/UDP/ICMP/DNS/AF_UNIX)

全部经 `make smoke-*` 一键复现；超时无 PASS 标记即失败（行为判据，非仅编译通过）。